KUPL 鲲鹏真实环境进展：数据图表

2026-11-05 至 2026-11-10（未打 tag，时点证据）

PyQCU

2026-11-10

读图约定

- 耗时单位秒（s）；带宽 GB/s（十进制）；利用率百分数。
- 柱上标注样本数或真实数值；n=1 一律视为单样本，不代表中位数。
- 范围值 a–b 画为 $(a+b)/2$ 加 $\pm(b-a)/2$ 的误差条，只表示样本内最小–最大，不是置信区间。
- 计算节点 `cn10579`（SVE2，16 CPU NUMA + 16 片上 NUMA，cpuset 上界 577）与登录节点 `login02/03`（Kunpeng-920，无 SVE，4 NUMA，共享机，无片上内存域）硬件不同，禁止跨类比较绝对值。
- 图注给出配置、窗口与证据边界；缺失项写“未验证”，不用估计值补位。
- 数据等级见第 7 节台账：**A** = 本地可复现原文；**B** = 阶段日志转述；**C** = 文档转述。

目录

1 绝对耗时与相对基线加速比 **2**

2 计算节点作业台账与几何不可比性 **3**

3 瓶颈归属与硬件上限 **4**

4 HBM 调用：早期失败与后期成功 **5**

5 登录节点筛选（辅助参考，非生产结论） **6**

6 Setup 成本、初始化与 opt-in 内核 **7**

7 证据台账 **8**

1 绝对耗时与相对基线加速比

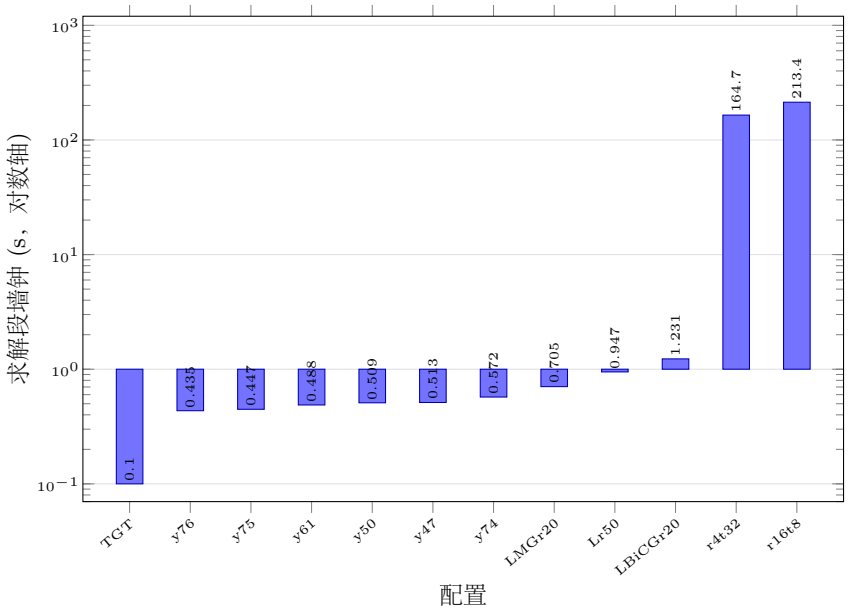


图 1: 绝对耗时（对数轴；柱上为真实秒数，不是 log10）。**计算节点** `cn10579`：y76 = 0.43456 s（32 ranks×12 threads，`grid` 1 1 1 32，16 迭代，独立真残差 3.5412×10^{-6}，n=1）；y75 = 0.44720 s（同配置，`atol`= 10^{-4}，16 迭代，n=1）；y61 = 0.48770 s（剖析同轮）；y50 = 0.5093 s；y47 = 0.5126 s；y74 = 0.57190 s（`atol`= 10^{-5}，18 迭代，n=1）；4 ranks×32 threads = 164.74992 s（作业 2049318，16 迭代，仅 native 残差 1.237×10^{-5}，未做独立残差）；16 ranks×8 threads = 213.44091 s（作业 2050917，`grid` 1 1 1 16，16 迭代，独立真残差 3.5411×10^{-6} PASS）。**登录节点**（共享机）：LBiCGr20 = 1.23078 s、LMGr20 = 0.70515 s（同窗 n=4 中位，`cc`=9、`fc`=29）；Lr50 = 0.94733 s（full-residual 伴随运行，只执行 1 次 coarse correction）。**口径警告**：16r×8t / 4r×32t 与 y76 的 ranks/threads/每 rank 局部体积不同，213.44/0.43456 = 491× 不能归因于 HBM 是否生效；只有 y76/y75/y61/y50/y47/y74 属同一 32×12 几何。

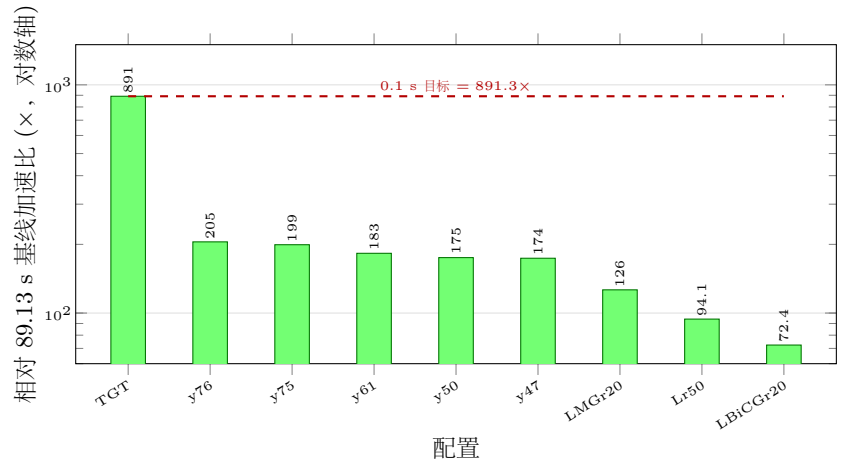


图 2: 相对 **89.13 s** 原始基线的加速比。原始基线为 4 ranks×32 threads、无 NUMA 映射、HBM 未生效、OpenMP 线程挤单核的历史运行；*本地不存在原始 report.json*，来源为日志转述（`logs/kupl_qcu_mg_instructions_20261105.txt`、`logs/resume-20261105T080514.gnF1tz.txt`），等级 C。该倍率混合了四项修复的合计效果（`set_mempolicy` 掩码对齐、逐线程绑核、NUMA 映射、rank-local slab），不是单项优化收益。登录节点两柱由登录节点中位折算，只表示量级，不与计算节点作性能比较。

2 计算节点作业台账与几何不可比性

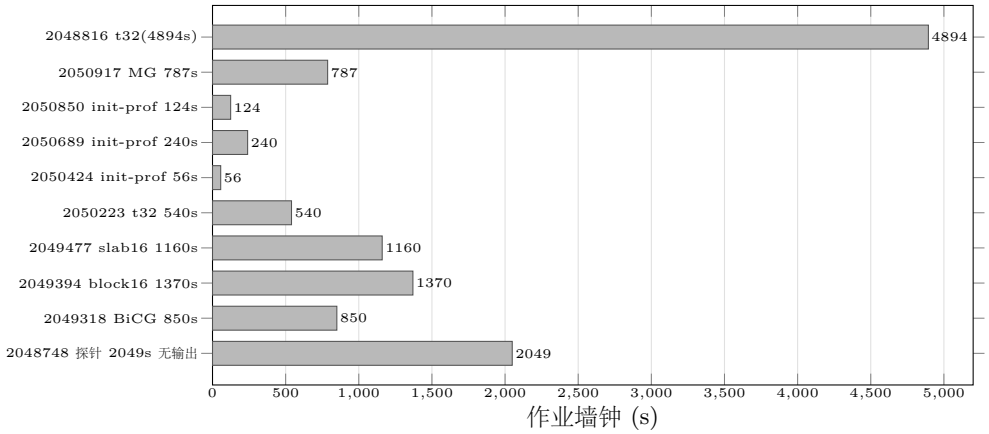


图 3: 计算节点作业墙钟台账（全部为本地可复现的调度器记录，等级 A）。**唯一完成求解的作业是两个**：2049318（4×32，BiCGStab 164.75 s，native 残差 1.237×10^{-5}，独立残差跳过）与 2050917（16×8，BiCGStab 213.44 s，独立真残差 3.5411×10^{-6} PASS）；后者的配对 MG case 在 787 s 无 `report.json`，经同队列本账号 TERM kill-job（2051058）终止，`jobExitCode=143`。2050850 是唯一 `END rc=0` 的完整初始化剖析作业（124 s）；2050689 在 240 s 内部超时（`rc=124`）。2048748 探针被接受并调度到 `cn10579`，但声明的 `y79.out` 路径未生成。**审计规则**：满 5 分钟查日志与进度，满 10 分钟且不能证明健康即终止并全面审查；未绕过 hook、未绕过 host-key、未操作其他用户进程。

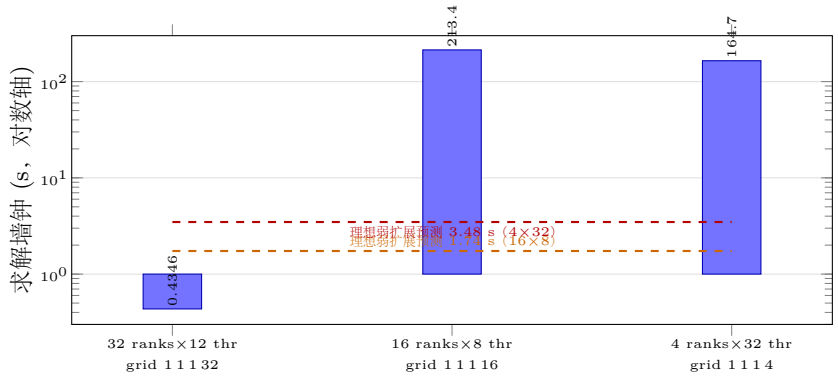


图 4: 计算节点三个求解点的几何差异量化。以 y76（32×12，每 rank 局部体积最小）为基准，按每 rank 局部体积线性外推：16×8 与 4×32 的局部体积分别为 2 倍与 1 倍，但 rank 数减半/降至 1/8，理想弱扩展预测应约为 1.74 s 与 3.48 s。实测为 213.4 s 与 164.7 s，分别高出 123× 与 47×。**结论**：该差距不可能由 HBM 是否生效解释，必须来自几何相关路径（局部体积放大后每 rank 的标量边界站点数、集合通信规模、以及 4×32 时 16 个 CPU/rank 的性能悬崖），当前**未分解**，不可当作 HBM 收益或损失。三项均未在同一窗口重复。

3 瓶颈归属与硬件上限

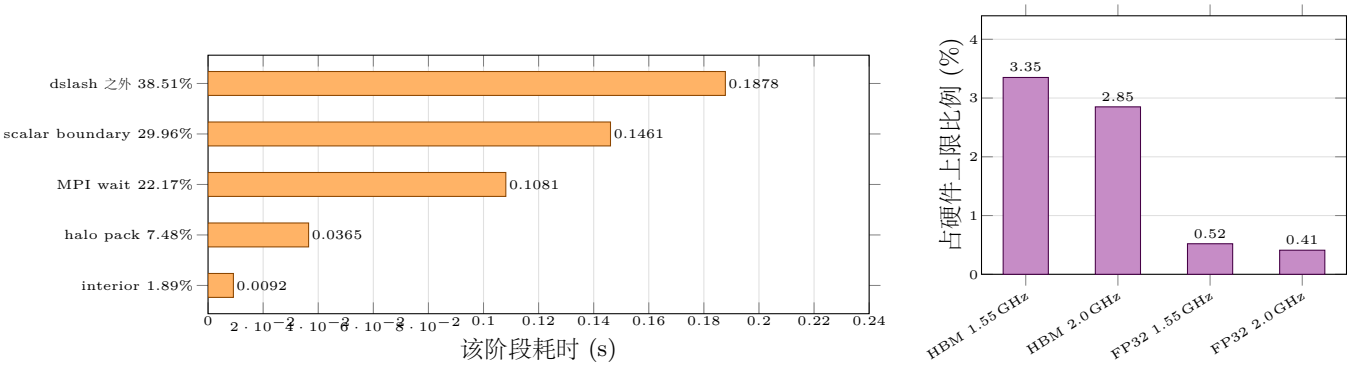


图 5: 左：y61（32 ranks×12 threads，$24^3 \times 64$ c64）dslash 剖析分解，dslash 共 84 次调用，四段合计 $0.1461 + 0.0365 + 0.1081 + 0.0092 = 0.2999$ s（61.49%），其余 0.1878 s（38.51%）在 dslash 之外。右：同一运行的 roofline 利用率。建模口径为"每 rank 每次 Schur apply 读一次 source、输出、两个 parity 规范场与 12×12 onsite 矩阵，无 cache 命中折扣"，34 次 apply 折算全局流量 60.51 GiB、算术 86.63 GFLOP，得 149.5 GB/s 与 199.4 GFLOP/s。分母取 384 线程推断上限：HBM 4.458 TB/s（1.55 GHz）/5.108 TB/s（2.0 GHz），FP32 SVE 38.09/49.15 TFLOP/s；HBM 两根柱分别是对 1.55 与 2.0 GHz 上限的比值，FP32 同理。**结论**：既非带宽受限也非算力受限，主因是 scalar 边界内核与全局同步。

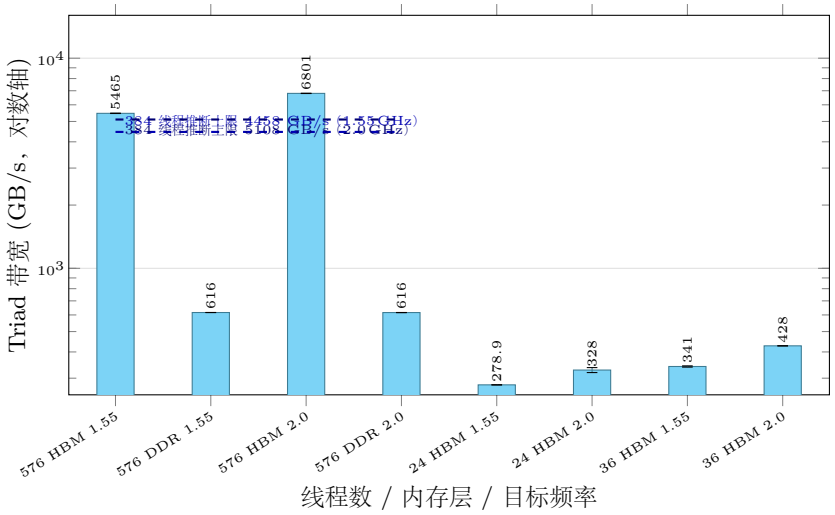


图 6: LX2 STREAM FP64 Triad 实测（源码与报告：`refer/kunpeng/lx2-stream-source/`）。口径为自定义 STREAM-style 固定窗口，每配置每操作 5 轮、共同计时窗口 0.15 s，逻辑读写量 ÷ 窗口时间，不是内存控制器实际字节。柱高为样本内最小–最大的中点，误差条为半幅（n 为 5–7 轮）。**取列更正**：单域 24 线程 1.55 GHz 的 Triad 是 **278.88** GB/s（源表该行 Copy 301.33 / Scale 301.44 / Add 278.65 / Triad 278.88）；`data/kupl_roofline_20261106.json` 记的 278.65 与 319.23 分别取自 Add 列，本图按源表更正。全节点 576 线程数据与源表一致。**限制**：384 线程上限由 16× 单域 t=24 推算，不是同时运行 384 线程的实测样本；两组频率来自不同样本，差异不能全部归因于频率。

4 HBM 调用：早期失败与后期成功

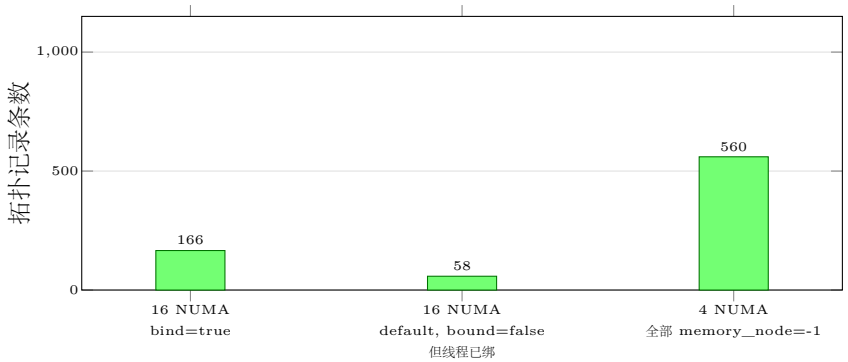


图 7: 日志中全部 PYQCU::KUPL::TOPOLOGY 记录的统计（共 784 条，logs/screen-73056-ss-…-*.txt，等级 A）。**166 条**为 memory_policy=bind 且 memory_bound=true，核心 16 个域到片上内存域 16–31 的配对完整；**58 条**为 memory_policy=default 且 memory_bound=false 但 bound_threads>0——这类运行只做 CPU 绑定，不能计为 HBM 运行；**560 条**为登录节点的 4 NUMA 记录，cpu_node=-1、cpuset=none、memory_node=-1，即根本没有 NUMA/片上内存放置。**验收边界**：memory_bound=true 只证明 set_mempolicy() 调用成功，不等于页实际落在片上内存；严格验收需在 solve 期间用 numastat -p 与 /proc/<pid>/numa_maps 取证，本项目**尚未采集**该 live 证据。

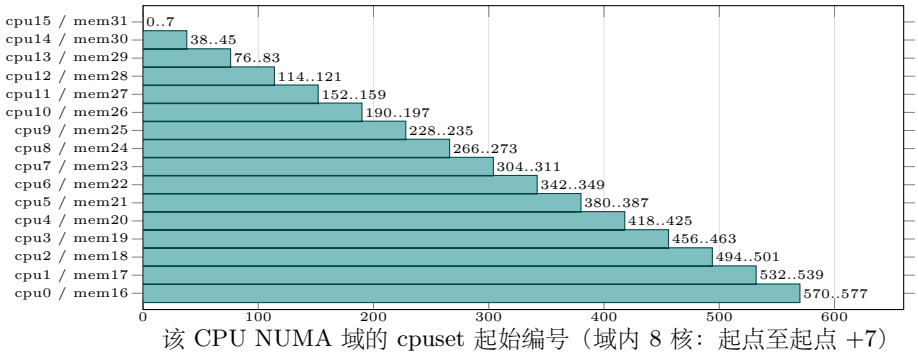


图 8: 计算节点 16 个 CPU NUMA 域到片上内存域的实测映射与 cpuset 范围（等级 A，来自 166 条 bind=true 记录）。cpuset 步长恒为 38（每域 38 核，8 线程运行只取前 8 个），最大 CPU 编号 577；$16 \times 38 = 608$，与 docs/kupl_kunpeng_guide.md 引用的“608 核、每域 38 核”示例机型参数一致。**注意**：memory_node 由配置 KUPL_MEMORY_NODE=local+16 决定，本图展示“配置生效后的配对”，不是系统自动发现；只在被调度到的运行中出现的域才有记录，故部分域样本数不同（7–22 条）。

5 登录节点筛选（辅助参考，非生产结论）

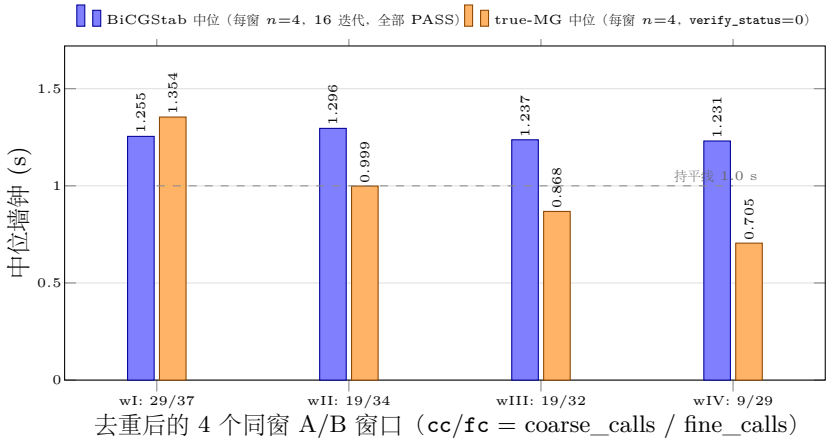


图 9: 登录节点 $24^3 \times 64$ c64、16 ranks×8 threads、`grid` 1 1 1 16、同 gauge/RHS、`atol`= 10^{-4}、`max_iter`= 50 的同窗 A/B（等级 A，本次从屏记录重算）。**只有 4 个去重窗口**，不是 6 个：`screen-126` 与 `screen-127` 的第一窗是同一组 8 个样本，`screen-128` 与 `screen-127` 的第二窗也是同一组；`screen-191/192` 是同一运行的两次偏移 hardcopy，其中 `bicgstab_2/3/4`、`mg_2/3/4` 六个样本完全相同，只有 `bicgstab_1`（1.6147 对 1.3008 s）与 `mg_1`（0.6422 对 0.7346 s）不同，因此 wIV 取 191 全集、192 只作复看，未另计窗口。比值 BiCG/MG：wI 0.927、wII 1.297、wIII 1.425、wIV 1.745（> 1 表示 MG 更快）。MAD（BiCG/MG）：wI 0.1018/0.0468；wII 0.0922/0.1818；wIII 0.0472/0.0786；wIV 0.0606/0.0431。**限制**：全部为共享登录节点，审计时 `load average`≈91/48、约 106 用户，同配置单样本可在 2.258–1.138 s 间波动；wI 与 wIV 的参数点不同，不得合并为"参数演进收益"。

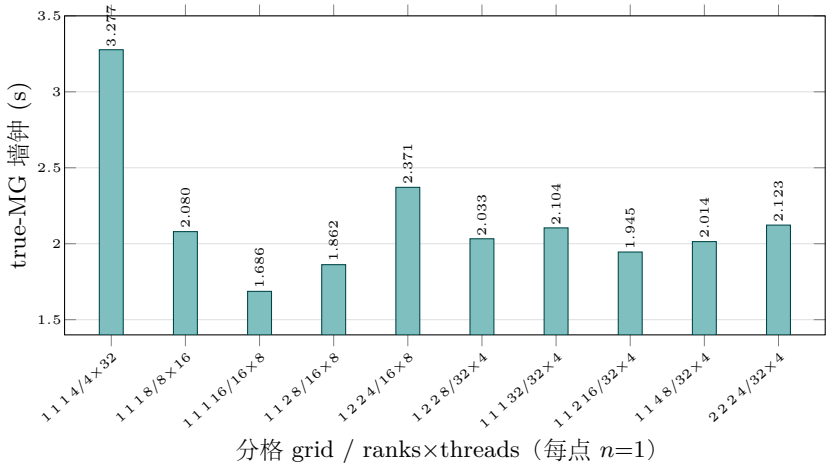


图 10: L24 true-MG 分格扫描（登录节点，每点 n=1），全部通过 `KUPL_REQUIRE_MG_CORRECTION` fail-closed 门且 `verify_status`= 0。最优为 1 1 1 16 的 1.68634 s；32 rank 点未进一步加速。**限制**：单样本；柱间差异同时包含共享负载漂移，只有同窗重复才能定为分格优劣。

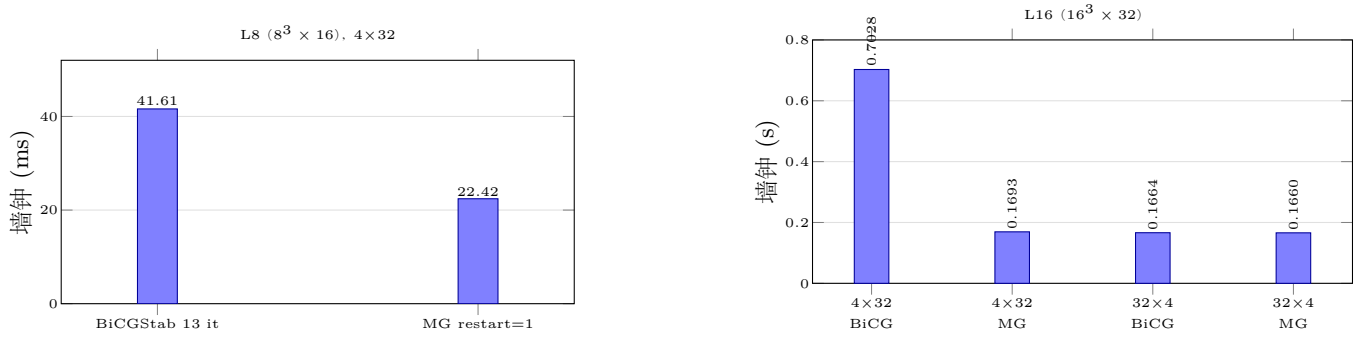


图 11: 小格点上 MG 与 BiCGStab 的对比（登录节点，等级 B，源自 `logs/kupl_hbm_opt_20261106.md` 的 L8/L16 表，*本地无对应 raw JSON*）。L8（$8^3 \times 16$、4×32）：BiCGStab 0.04161 s（13 迭代）对 MG `restart=1` 0.02242 s，约 1.86×。L16（$16^3 \times 32$）：4×32 时 MG 0.16925 s 对 BiCGStab 0.70283 s，约 4.15×；但 32×4 时两者几乎持平（MG 0.16597 s 对 BiCGStab 0.16635 s，约 1.002×），说明粗层工作与小消息同步在 rank 数上升后抵消了迭代优势。**因此 BiCG 与 MG 必须分格调优**，不能沿用同一 `grid`。L16 中 16×8 与 32×4 的 MG 分别为 0.13384 / 0.16597 s（同一文档另一表），两张表来自不同分格矩阵，不可逐点混算。

6 Setup 成本、初始化与 opt-in 内核

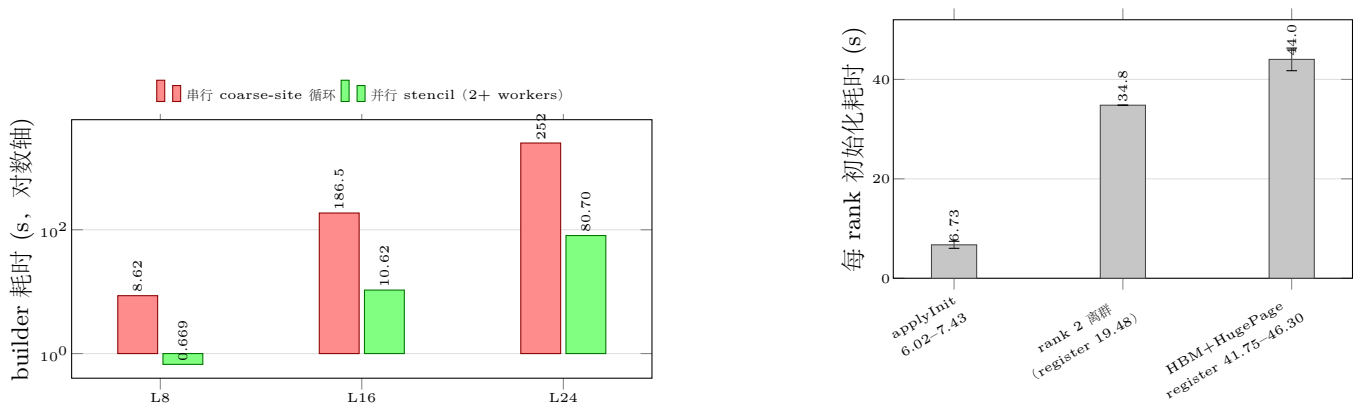


图 12: 左：MG cache builder 串行 vs 并行（`KUPL_ENABLE_MG_STENCIL_PARALLEL=1`，默认关闭，等级 B）。加速比 12.9× / 17.6× / > 31×；L8 与 L16 的 gram/Galerkin 数值完全一致，L24 为 gram 1.55×10^{-6}、Galerkin 3.58×10^{-7}。**带星号的 2520 s 是外推值**：由“stencil 1382/27648 用 125.98 s”推得约 42 min，不是实测完成值（该次已终止）。右：计算节点初始化（等级 A）。作业 2050850（16 rank，`END rc=0`，总墙钟 124 s）中 15 个 rank 的 `applyInit`/`applyEnd` 为 6.02–7.43 s（柱为中值 6.73 s、半幅 0.71 s），rank 2 为 34.81 s 离群；真实 HBM 运行（y91，`KUPL_HUGEPAGE=1`）中 `register` 升至 41.75–46.30 s（柱为中值 44.03 s、半幅 2.28 s），并出现一次 `erase` 7.80 s。**该成本在 `wall_seconds` 之外**，必须与求解内核分栏报告。

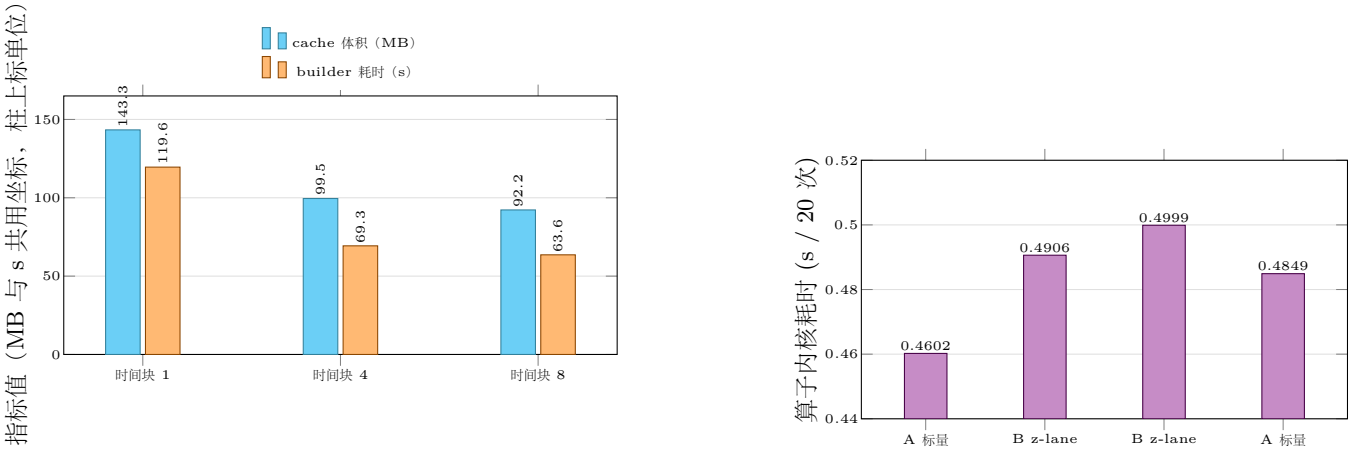


图 13: 左：L24 时间块对 cache 体积与 builder 成本的影响（等级 B）。时间块 1/4/8 的 cache 分别为 143.3/99.5/92.2 MB（原始字节 143,335,424 / 99,540,992 / 92,241,920），builder 为 119.57/69.33/63.59 s，合法最大 `grid_t` 为 32/8/4；三者在 solve 阶段都慢于时间块 1，build 节省不抵粗层同步成本。右：`KUPL_ENABLE_T2_ZBLOCK_DSLASH=1`（z-lane 向量化）的 A-B-B-A 复测（32 ranks×4 threads，全局 $24^3 \times 64$，仅 Schur，20 次/块，norm-checked，等级 B）。标量中位 0.47257 s、z-lane 中位 0.49525 s，z-lane 慢 4.8%；编译器同时报告循环向量化失败，该候选保持 opt-in。

7 证据台账

表 1: 本文引用的关键数值及其出处等级。**A** = 本地可复现原文（屏幕 hardcopy/日志原文）；**B** = 阶段日志转述（本地无 raw JSON）；**C** = 文档转述，本地无任何原文。

数值	含义	出处	级
0.43456275 s / 16 it	y76 计算节点 BiCGStab	`logs/kupl_hbm_opt_20261106.md`（未入库）；`logs/v202611061446.txt`	B
0.4472 / 0.5719 s	y75 / y74 单样本	`logs/resume-20261105T080514.gnF1tz.txt`	B
0.4877 / 0.5093 / 0.5126 s	y61 / y50 / y47	`logs/kupl_qcu_mg_performance_reference_20261105.txt`	B
0.475 s	历史最低（安静节点）	同上	B
0.9473317482 s	`restart=50` full-residual	`logs/screen-73056-ss-20261106-193..195.txt`	A
1.23078 / 0.70515 s	登录节点 r20 窗口中位	`screen-…-191/192.txt`（本次重算）	A
1.2546 / 1.3541 s	登录节点早期窗口中位	`screen-…-123.txt`（本次重算）	A
1.3972 / 0.78976 s	文档所记 r10 中位	`logs/v20261106104704.txt`；`screen-127.txt`	A/B
1.09187 / 0.70424 s	文档所记 r50 同窗中位	仅 `logs/v20261106114436.txt`	B
213.44090568200045 s	作业 2050917 的 16×8 求解	`screen-1829-bicg-report.txt`	A
164.7499241 s	作业 2049318 的 4×32 求解	`logs/kupl_hbm_opt_20261106.md`	B
8.617 / 186.52 / 80.70 s	串行 L8/L16、并行 L24 builder	同上	B
0.70283 / 0.16925 / 0.16597 s	L16 BiCG/MG@4、MG@32	同上	B
89.13 s	原始基线（4×32，无映射）	指令日志转述	C

表 2: 计算节点作业台账（全部等级 A，调度器记录）。“—”表示该作业未产生求解报告。

作业	类型	ranks×thr	墙钟 (s)	结局	等级
2048748	1-rank 探针	1×1	—	被接受并调度到 cn10579，声明的 `y79.out` 未生成	A
2048816	32-rank A/B	32×12	4894	host pre-hook 后无 case stdout，同队列 kill，exit 143	A
2048893	16-rank 提交	16	—	被接受但未出现在活动作业查询	A
2049318	4-rank A/B	4×32	850	BiCGStab 164.75 s PASS（native 残差）；配对 MG 10 min 门后 kill，exit 143	A
2049394	block 路径屏	16×8	1370	仅拓扑输出，exit 143	A
2049477	slab 路径屏	16×8	1160	仅拓扑输出，exit 143	A
2050223	t-only 屏	32×4	540	无 report	A
2050424	init 剖析	16×8	56	`END rc=0`，v1 目录	A
2050689	init 剖析	16×8	240	内部超时 `rc=124`，停在 topology-report	A
2050850	init 剖析	16×8	124	`END rc=0`，全部 16 rank 完成	A
2050917	MG 正式	16×8	787	无 `report.json`，TERM kill-job 2051058，exit 143	A
2051058	kill-job	1×1	—	同队列本账号 TERM，成功	A